Distribución muestral

Lenguaje de la teoría de muestreo

Parámetro → medida que describe una característica de la población

μ_x σ_x σ_x^2

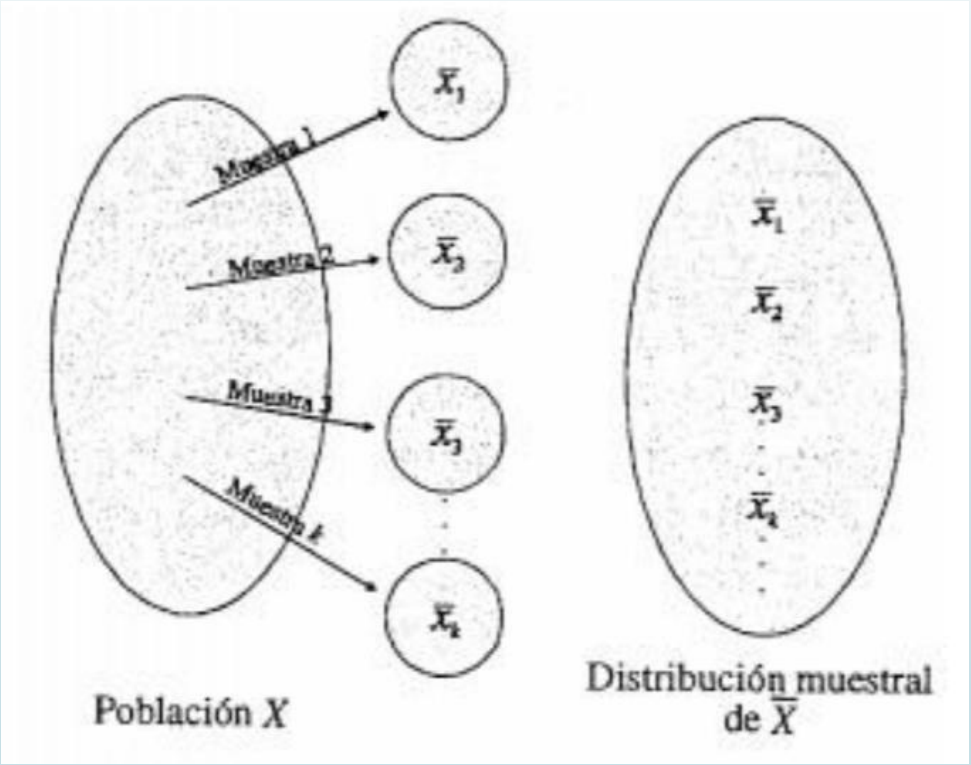
estimador

Estadístico → medida que describe una característica de la muestra

$\bar{X}$ S S^2

Distribución muestral de medias

Si de una población se extraen muestras de tamaño n y a cada una se le calcula su media; el conjunto de valores de $\bar{X}$ forman la distribución muestral de medias.



Poblaciones infinitas

- Si se extraen m muestras de tamaño n de una población con media μ_x desviación estándar σ_x se verifica que:

1) $\mu_x = \mu_{\bar{x}}$

2) $\frac{\sigma_x^2}{n} = \sigma_{\bar{x}}^2$

3) $\frac{\sigma_x}{\sqrt{n}} = \sigma_{\bar{x}}$

Demostraciones

Siendo M el número de muestras posibles

$$\mu_{\bar{x}} = \frac{\sum \bar{x}_i}{M} = \frac{\bar{x}_1 + \bar{x}_2 + \bar{x}_3 \quad + \bar{x}_M}{M} = \mu$$

$$\sigma_{\bar{x}} = \sqrt{\frac{\sum \left(\bar{x}_i - \mu\right)^2}{M}} = \sqrt{\frac{(\bar{x}_1 - \mu)^2 + (\bar{x}_2 - \mu)^2 \quad + (\bar{x}_M - \mu)^2}{M}} = \frac{\sigma}{\sqrt{n}}$$

Poblaciones finitas

- Si se extraen m muestras de tamaño n de una población con media μ_x desviación estándar σ_x se verifica que:

1) $\mu_x = \mu_{\bar{x}}$

2) $\sigma^2_{\bar{x}} = \frac{\sigma^2_x}{n} \cdot \frac{N-n}{N-1}$

3) $\sigma_{\bar{x}} = \frac{\sigma_x}{\sqrt{n}} \cdot \sqrt{\frac{N-n}{N-1}}$

Si la muestra de tamaño n se extrae de una población de tamaño N, y se muestrea más del 5% de la población $\left(\frac{n}{N} \geq 0{,}05\right)$ debe usarse el factor de corrección por población finita (cpf).

Ejemplo 1

De una población **1 2 3**, se extraen todas las muestras posibles de tamaño 2 con reposición y se halla la distribución muestral de medias.

comb.	1-1	1-2	1-3	2-1	2-2	2-3	3-1	3-2	3-3
$\bar{X}$	1	1.5	2	1.5	2	2.5	2	2.5	3

$\bar{X}$	1	1.5	2	2.5	3
fi	1	2	3	2	1



Distribución muestral de medias

Además, se comprueba que:

$$\mu_x = 2 \qquad \sigma_x = 0{,}82 \qquad \sigma_x^2 = 0{,}67$$

$$\mu_{\bar{x}} = 2 \qquad \sigma_{\bar{x}} = 0{,}58 \qquad \sigma_{\bar{x}}^2 = 0{,}33$$

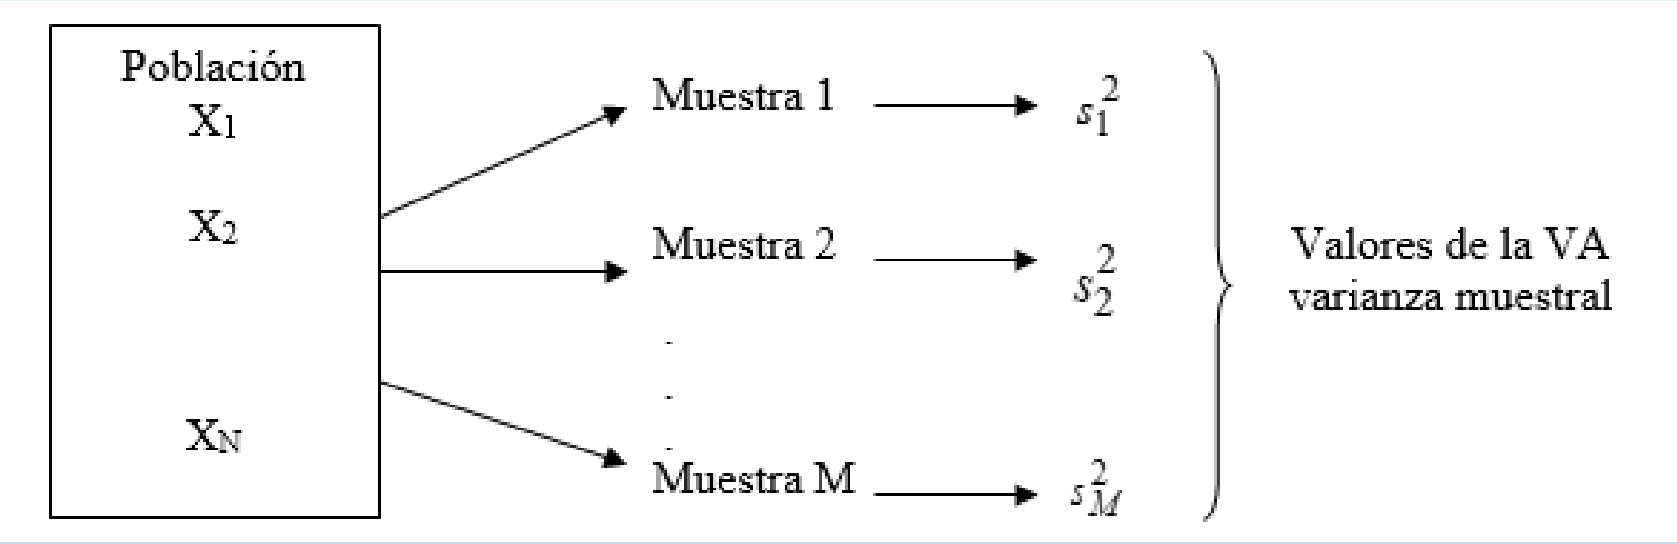
$$\mu_x = \mu_{\bar{x}} = 2$$

$$\sigma_{\bar{x}}^2 = \frac{\sigma_x^2}{n} = \frac{0{,}67}{2} = 0{,}33$$

$$\sigma_{\bar{x}} = \frac{\sigma_x}{\sqrt{n}} = \frac{0{,}82}{\sqrt{2}} = 0{,}58$$

Distribución muestral de varianzas

Si de una población se extraen muestras de tamaño n y a cada una se le calcula su varianza; el conjunto de valores de S^2 forman la distribución muestral de varianzas.



Ejemplo 2

De una población **2 4 6 8**, se extraen todas las muestras posibles de tamaño 2 sin reemplazo. Y se halla la distribución muestral de varianzas.

comb.	2-4	2-6	2-8	4-6	4-8	6-8
$\bar{X}$	3	4	5	5	6	7
S^2	1	4	9	1	4	1

S^2	1	4	9
fi	3	2	1

Distribución muestral de varianzas

Si promediamos las varianzas de las muestras de tamaño dos, ¿cuál es su media? ¿Cómo se escribe simbólicamente? ¿Coincide con el valor de la varianza poblacional?

$$\mu_{S^2} = 3{,}33 \quad y \quad \sigma_x^2 = 5 \quad \rightarrow \mu_{S^2} \neq \sigma_x^2$$

Varianza corregida

- Nos brinda mayor precisión y se define de la siguiente forma:

$$\hat{S}^2 = S^2 \cdot \frac{n}{n-1}$$

- También se cumple que:

1) $\mu_{\hat{S}^2} = \sigma_x^2$

2) $\mu_{\hat{S}^2} = \frac{N}{N-1} \cdot \sigma_x^2$

3) $\mu_{S^2} = \frac{n-1}{n} \cdot \sigma_x^2$

4) $\mu_{S^2} = \frac{N}{N-1} \cdot \frac{n-1}{n} \cdot \sigma_x^2$

¿Por qué usar $n-1$ en lugar de n?

- Cuando calculamos $\bar{x}$ (la media de la muestra), usamos información de la misma muestra. Por eso ya "utilizamos" un grado de libertad.
- Si dividiéramos por n, estaríamos subestimando la variabilidad real de la población (tiende a quedar sesgado hacia valores más bajos).
- Al dividir por $n-1$, estamos corrigiendo ese sesgo, de modo que el valor esperado de s^2 sea igual a la varianza poblacional σ^2. Es decir: $E(s^2) = \sigma^2$.

Interpretación práctica:

- En software estadístico (R, Python, SPSS, Excel), cuando calculás la "varianza de la muestra", casi siempre se usa la corrección $n-1$ por defecto (aunque algunos programas permiten elegir).
- Esta corrección es especialmente importante cuando el tamaño de muestra es pequeño. Para muestras muy grandes, la diferencia entre dividir por n o $n-1$ es mínima.

Demostración

Varianza corregida

$$\hat{s}^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}{n-1} \quad (I)$$

Varianza sin corregir

$$s^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}{n} \quad (II)$$

Si la expresión II la multiplicamos y dividimos por n-1 se obtiene:

$$s^2 = \frac{n-1}{n} \cdot \boxed{\frac{1}{n-1} \cdot \sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2} \longrightarrow$$

Definición de varianza corregida

$$s^2 = \frac{n-1}{n} \cdot \hat{s}^2$$

Además, se comprueba que:

$$\mu_x = 5 \qquad \sigma_x = 2{,}24 \qquad \sigma_x^2 = 5$$

$$\mu_{S^2} = 3{,}33$$

$$\mu_{S^2} = \frac{N}{N-1} \cdot \frac{n-1}{n} \cdot \sigma_x^2$$
$$= \frac{4}{4-1} \cdot \frac{2-1}{2} \cdot 5$$
$$= 3{,}33$$

Si para el ejemplo anterior hallamos la distribución muestral de varianzas corregidas:

Muestras		Media	Varianza	Varianza corregida
2	4	3	1	2
2	6	4	4	8
2	8	5	9	18
4	6	5	1	2
4	8	6	4	8
6	8	7	1	1

$\hat{S}^2$	2	8	18
fi	3	2	1

Distribución muestral de varianza corregida

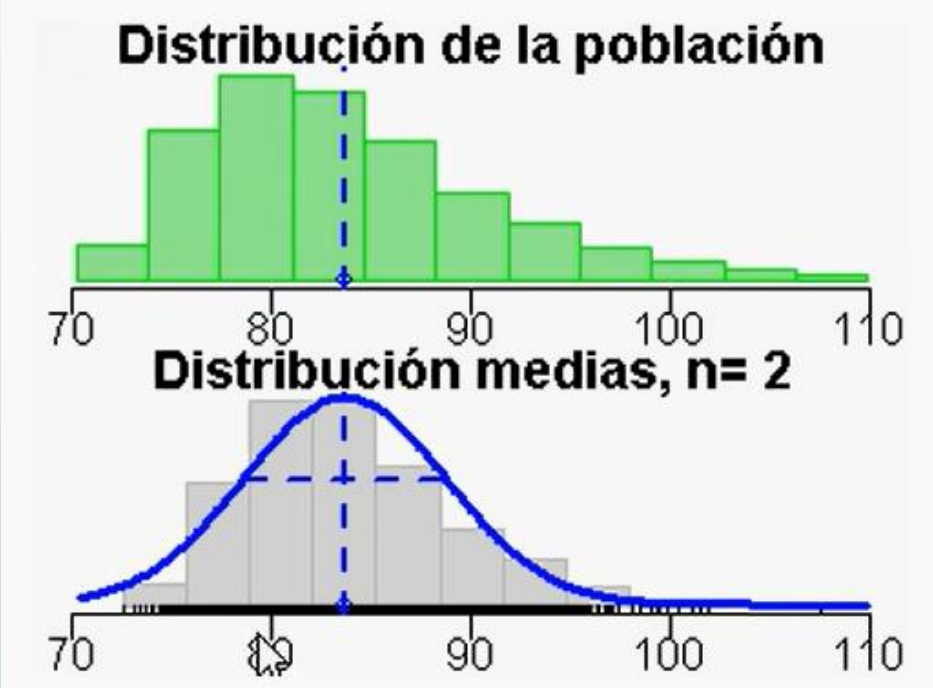
$$\mu_{\hat{s}^2} = \frac{N}{N-1} \cdot \sigma_x^2$$

$$\mu_{\hat{s}^2} = \frac{4}{3} \cdot 5$$

$$\mu_{\hat{s}^2} = 6,66$$

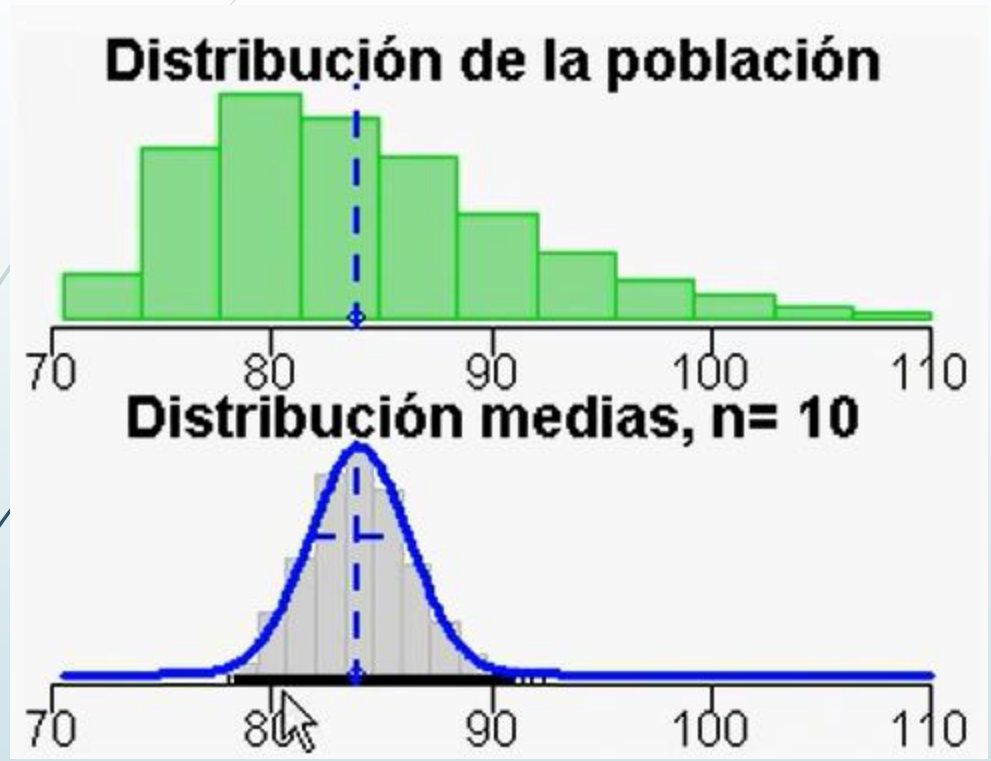
Teorema central del límite

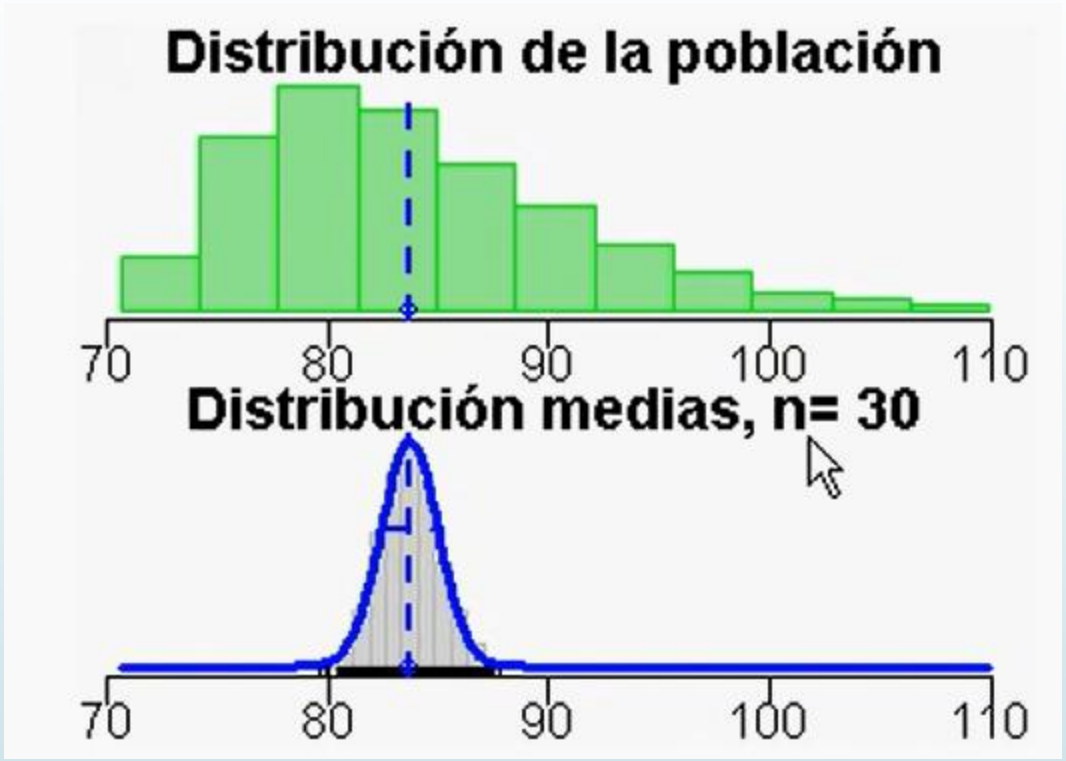
La distribución muestral de la media es aproximadamente normal si la población de la que procede la muestra no es normal. Mientras mayor sea el tamaño de la muestra, más cerca estará la distribución muestral de ser normal.



Las medias muestrales toman valores más moderados, se agrupan en forma más compacta con respecto al centro

Disminuye la variabilidad al aumentar el tamaño de la muestra





La distribución de la media de las muestras se parece mucho a una distribución normal y esta es la razón fundamental porque es tan importante la distribución Gaussiana.

https://www.youtube.com/watch?v=xZmFqLHIFJk

Si se seleccionan muestras aleatorias de n observaciones de una población conociendo la media y la desviación (para poblaciones infinitas), entonces si n es grande, la distribución muestral de medias tendrá aproximadamente una distribución normal con media y desviación:

$$\mu_x = \mu_{\bar{x}} \qquad \frac{\sigma_x}{\sqrt{n}} = \sigma_{\bar{x}}$$

Y para poblaciones finitas:

$$\mu_x = \mu_{\bar{x}} \qquad \sigma_{\bar{x}} = \frac{\sigma_x}{\sqrt{n}} \cdot \sqrt{\frac{N-n}{N-1}}$$

Ejemplo

3) El pago por hora para los trabajadores de cierta planta automotriz se distribuye normalmente con una media de 12.5 dólares y una desviación estándar de 0.95; si de esta fábrica se elige una muestra aleatoria de 100 trabajadores, encuentre la probabilidad de que la media del pago por hora:

a) Sea menor de 12.6 dólares.

b) Esté entre 12.45 y 12.65 dólares.

c) Supere los 12.3 dólares.

$$\mu_x = 12{,}5 \qquad \sigma_x = 0{,}95 \qquad n = 100$$

$$\mu_x = \mu_{\bar{x}} = 12{,}5 \qquad \sigma_{\bar{x}} = \frac{\sigma_x}{\sqrt{n}} = 0{,}095$$

$a)\ P(\bar{X} < 12{,}6) = 0{,}8537$

$b)\ P(12{,}45 < \bar{X} < 12{,}65) = P(\bar{X} < 12{,}65) - P(\bar{X} < 12{,}45) = 0{,}9428 - 0{,}2993 = 0{,}6435$

$c)\ P(\bar{X} > 12{,}3) = 0{,}9824$



EJEMPLO Seguridad de taxis acuáticos En el problema del capítulo señalamos que algunos pasajeros murieron cuando un taxi acuático se hundió en el Inner Harbor de Baltimore. Los hombres suelen ser más pesados que las mujeres y los niños; por lo tanto, supongamos que al cargar un taxi acuático la situación extrema es aquella en la que todos los pasajeros son hombres. En concordancia con los datos de la National Health and Nutrition Examination Survey, suponga que los pesos de los hombres se distribuyen normalmente, con una media de 172 libras y una desviación estándar de 29 libras.

a. Calcule la probabilidad de que, si se selecciona un hombre al azar, su peso sea mayor que 175 libras.

b. Calcule la probabilidad de que 20 hombres elegidos al azar tengan una media mayor que 175 libras (de manera que su peso total exceda la capacidad segura de 3500 libras).

SOLUCIÓN

a. *Enfoque: Utilice los métodos presentados en la sección 6-3* (porque estamos trabajando con un valor individual de una población distribuida normalmente). Buscamos el área de la región sombreada en la figura 6-19a). Si utilizamos la tabla A-2, convertimos el peso de 175 a su puntuación z correspondiente:

$$z = \frac{x - \mu}{\sigma} = \frac{175 - 172}{29} = 0.10$$

Nos remitimos a la tabla A-2 y utilizamos $z = 0.10$ para encontrar que el área acumulativa a la izquierda de 175 libras es 0.5398. Por lo tanto, la región sombreada es $1 - 0.5398 = 0.4602$. La probabilidad de que un hombre elegido al azar pese más de 175 libras es de 0.4602. (Si se utiliza una calculadora o un programa de cómputo en vez de la tabla A-2, el resultado más exacto es 0.4588 en lugar de 0.4602).

b. *Enfoque: Utilice el teorema del límite central* (porque estamos trabajando con la *media de una muestra* de 20 hombres y no con un solo hombre). Aun cuando el tamaño de la muestra no es mayor que 30, utilizamos una distribución normal por la siguiente razón: la población original de hombres tiene una distribución normal, de manera que las muestras de *cualquier* tamaño producirán medias distribuidas normalmente. Puesto que estamos trabajando con una distribución de medias muestrales, debemos utilizar los parámetros $\mu_{\bar{x}}$ y $\sigma_{\bar{x}}$, que se evalúan de la siguiente manera:

$$\mu_{\bar{x}} = \mu = 172$$

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{29}{\sqrt{20}} = 6.4845971$$

He aquí un punto realmente importante: debemos utilizar la desviación estándar calculada de 6.4845971 y no la desviación estándar original de 29 (porque estamos trabajando con la distribución de medias muestrales cuya desviación estándar es 6.4845971, y no con la distribución de pesos individuales cuya desviación estándar es 29). Necesitamos calcular el área sombreada que se destaca en la figura 6-1b). Si usamos la tabla A-2, obtenemos la puntuación z relevante, que se calcula de la siguiente manera:

$$z = \frac{\bar{x} - \mu_{\bar{x}}}{\sigma_{\bar{x}}} = \frac{175 - 172}{\frac{29}{\sqrt{20}}} = \frac{3}{6.4845971} = 0.46$$

Si nos remitimos a la tabla A-2, encontramos que $z = 0.46$ corresponde a una área izquierda acumulativa de 0.6772, de manera que la región sombreada es $1 - 0.6772 = 0.3228$. La probabilidad de que 20 hombres tengan un peso medio mayor que 175 libras es de 0.3228. (Si se utiliza una calculadora o un programa de cómputo, el resultado es 0.3218 en vez de 0.3228).