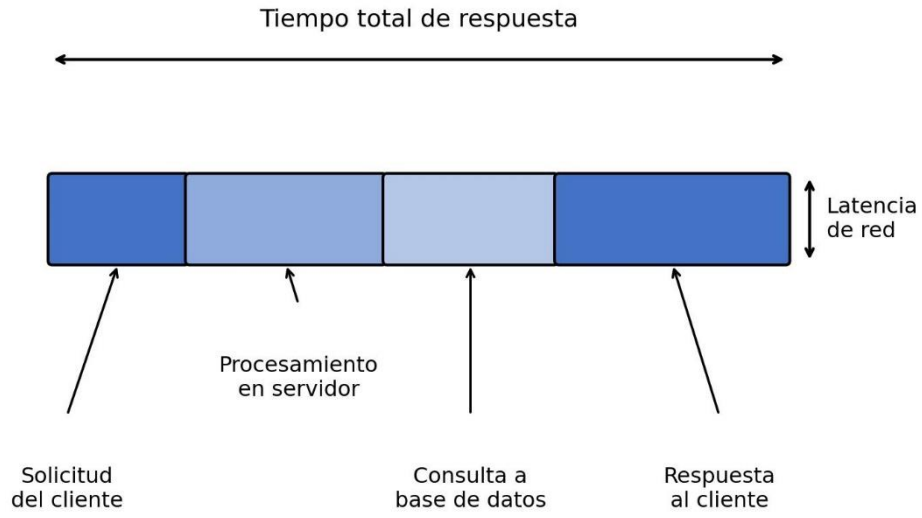
PROBLEMA 1

¿Cumplen el SLA?

”Imagina que una empresa de desarrollo gestiona la pasarela de pagos de un e-commerce. Su Acuerdo de Nivel de Servicio (SLA) exige que el tiempo de respuesta de cada transacción esté entre 220 ms y 280 ms. El sistema tiene un tiempo de respuesta promedio de 250 ms, pero por la carga del servidor y la latencia de red, el tiempo varía un poco, con una dispersión aproximada de σ = 15 ms.

El líder del equipo de infraestructura pregunta: “Si hoy se procesan 1000 transacciones, ¿aproximadamente cuántas cumplirán el SLA y cuántas quedarán fuera?”



PROBLEMA 2

El ancho de banda que un proveedor de internet entrega a sus clientes residenciales tiene una media de $\mu = 95$ Mbps, con desviación estándar $\sigma = 4$ Mbps. ¿Qué porcentaje de mediciones será rechazado (no cumple el mínimo contractual), si no se aceptan velocidades inferiores a 87 Mbps?

Modelos Probabilísticos Continuos

Modelos Probabilísticos Continuos

Distribución Normal



Distribución T de Student

Distribución Chi Cuadrado

Distribución Normal

Hay numerosas variables que siguen una forma de variación análoga a la normal

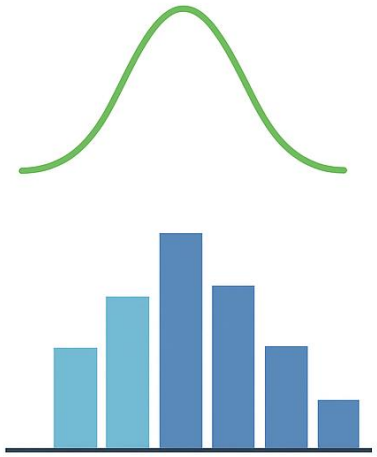
Es buena como aproximación de otras distribuciones

Entre las funciones de densidad, la distribución normal es la más importante, debido principalmente a que hay muchas variables asociadas a fenómenos naturales que siguen un comportamiento que, al graficarse, tienen forma de campana. Estas variables pueden referirse a:

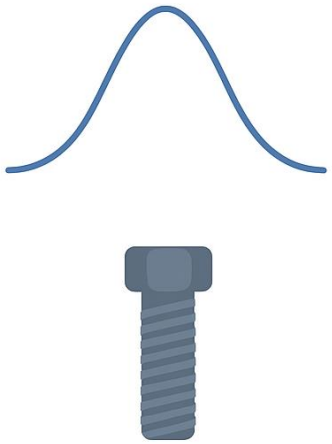
- Caracteres morfológicos de personas, animales o plantas, como tallas, pesos, diámetros, perímetros, etcétera.
- Caracteres fisiológicos, por ejemplo, efecto de una misma dosis de un fármaco
- Caracteres sociológicos, puntuaciones obtenidas en un examen.
- Caracteres psicológicos, como el cociente intelectual o el grado de adaptación a un medio, entre otros.
- Errores cometidos al medir ciertas magnitudes.
- Otras distribuciones como la binomial o la de Poisson pueden aproximarse a una distribución normal.



Altura de personas



Calificación de un examen



Variación en medidas industriales

DISTRIBUCIÓN NORMAL

DEFINICION 6.3.1 Una variable aleatoria contínua X, se dice que está *distribuída normalmente*, con media μ $(-\infty < \mu < \infty)$ y varianza $\sigma^2 > 0$, si su función de densidad de probabilidad esta dado por,

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(1/2)[(x-\mu)/\sigma]^2} \quad , \quad -\infty < x < \infty$$

donde $\pi = 3.14159 \ldots$ y $e = 2.71828 \ldots$

NOTACION Una notación muy usada para la distribución normal es,

$$X \rightarrow N(\mu , \sigma^2)$$

que se lee: "la variable aleatoria X se distribuye normalmente con media μ y varianza σ^2" (se usa también la notación $X \rightarrow N(\mu,\sigma)$, que se lee: "X tiene una distribución normal con media μ y desviación estándar σ").

FUNCIÓN DE DENSIDAD

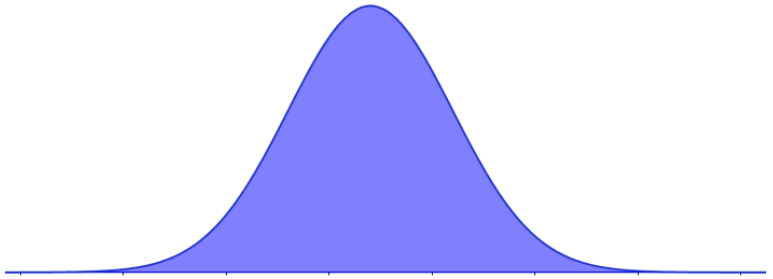
$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{1}{2}\cdot\left(\frac{x-\mu}{\sigma}\right)^2}$$

CARACTERÍSTICAS

1. La distribución normal se conoce también como campana de Gauss en honor a Karl F. Gauss y debido a que tiene forma de campana

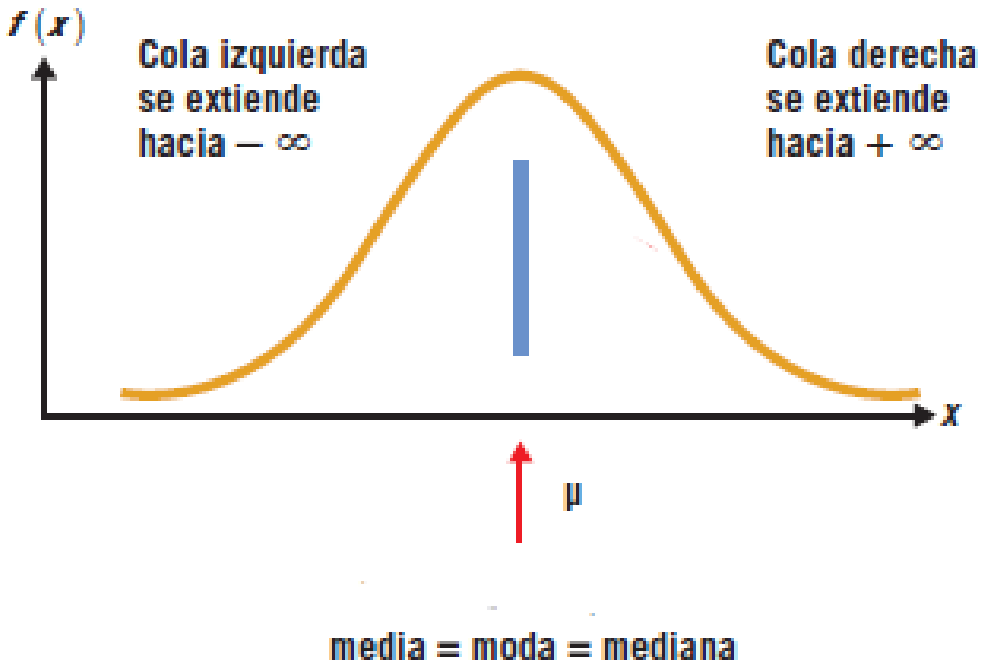


2. Por ser una distribución de probabilidad , el área bajo la curva es 1, es decir, el área limitada entre la curva normal y el eje x es 1.



3. Es una distribución asintótica, es decir, cuando *x* tiende a $-\infty$ o a $+\infty$, la función tiende a cero.

4. Es una distribución simétrica respecto a la media (μ). Además, la media, la moda y la mediana tienen el mismo valor.



5. El punto máximo se encuentra en $(\mu;\ \frac{1}{\sigma.\sqrt{2\pi}})$

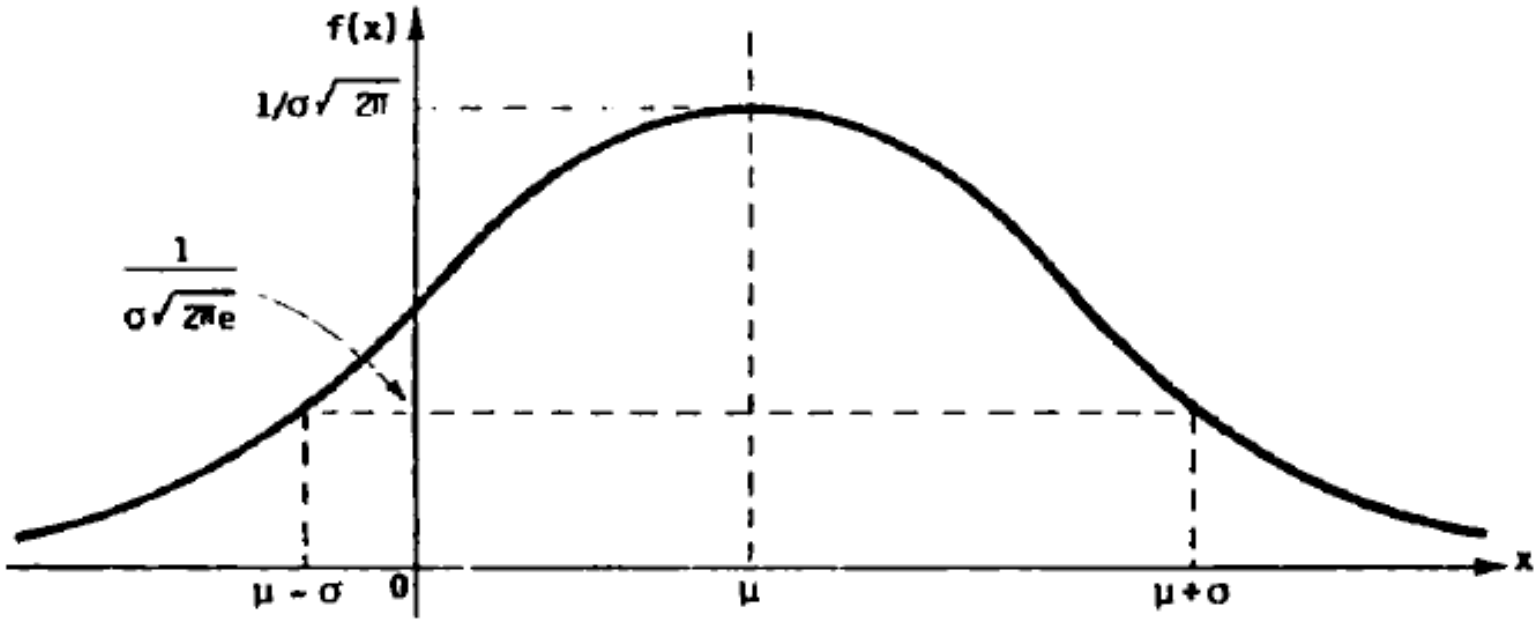


Fig. 6.3.1 La distribución normal.

6. Los puntos de inflexión, donde cambia de curvatura la función, se encuentran en $(\mu - \sigma\ ,\ \frac{1}{\sigma\sqrt{2\pi e}})$ y $(\mu + \sigma,\ \frac{1}{\sigma\sqrt{2\pi e}})$

. Entonces, la gráfica de f es cóncava hacia arriba en $\langle -\infty,\ \mu - \sigma\rangle$, cóncava hacia abajo en $\langle \mu - \sigma\ ,\ \mu\rangle$ y $\langle \mu, \mu+\sigma\rangle$, cónva-va hacia arriba en $\langle \mu + \sigma\ ,\ \infty\ \rangle$

INFLUENCIA DE LOS PARÁMETROS EN LA CURVA NORMAL

Los parámetros que determinan completamente la distribución normal son, su media y su varianza

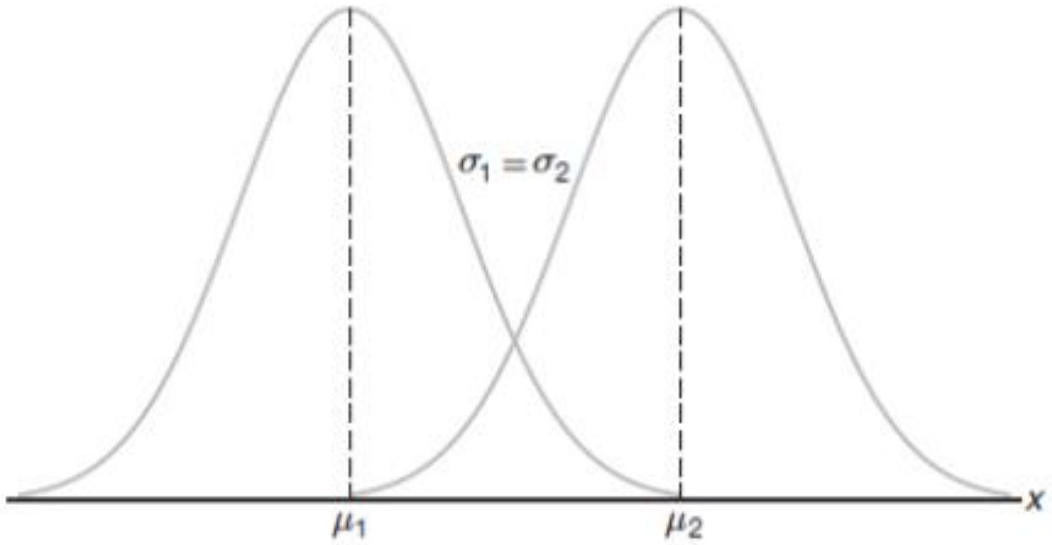
$$\mu_1 < \mu_2$$

La curva se desplaza con respecto al eje horizontal

$$\sigma_1 = \sigma_2$$

$\mu \Rightarrow$ Desplazamiento

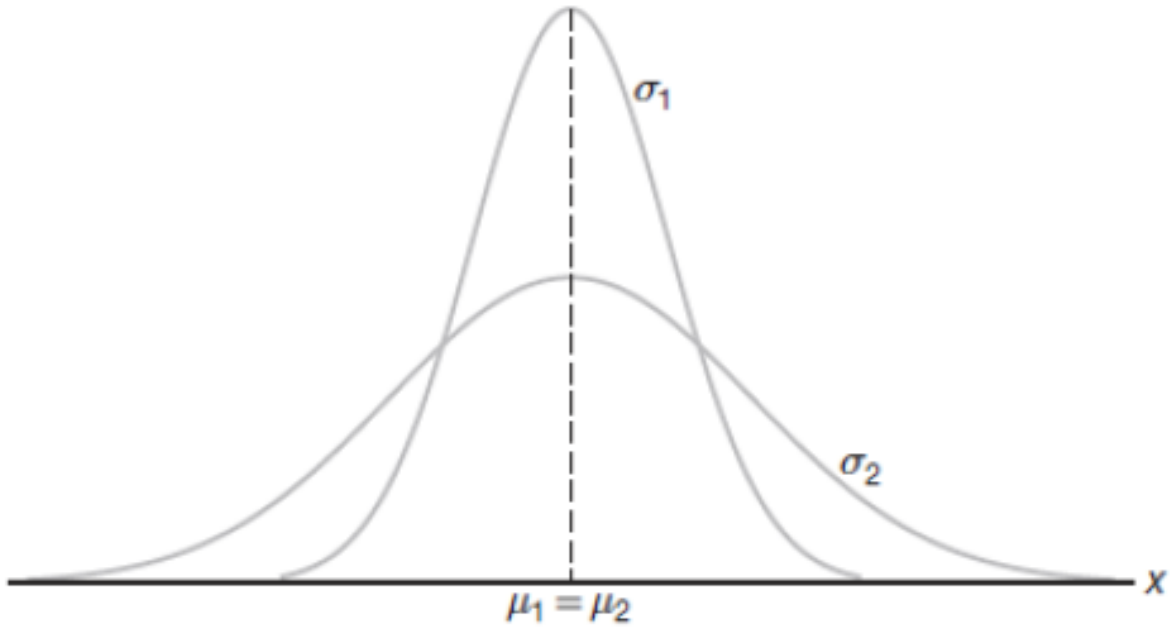
$\sigma \Rightarrow$ Forma



$$\mu_1 = \mu_2$$

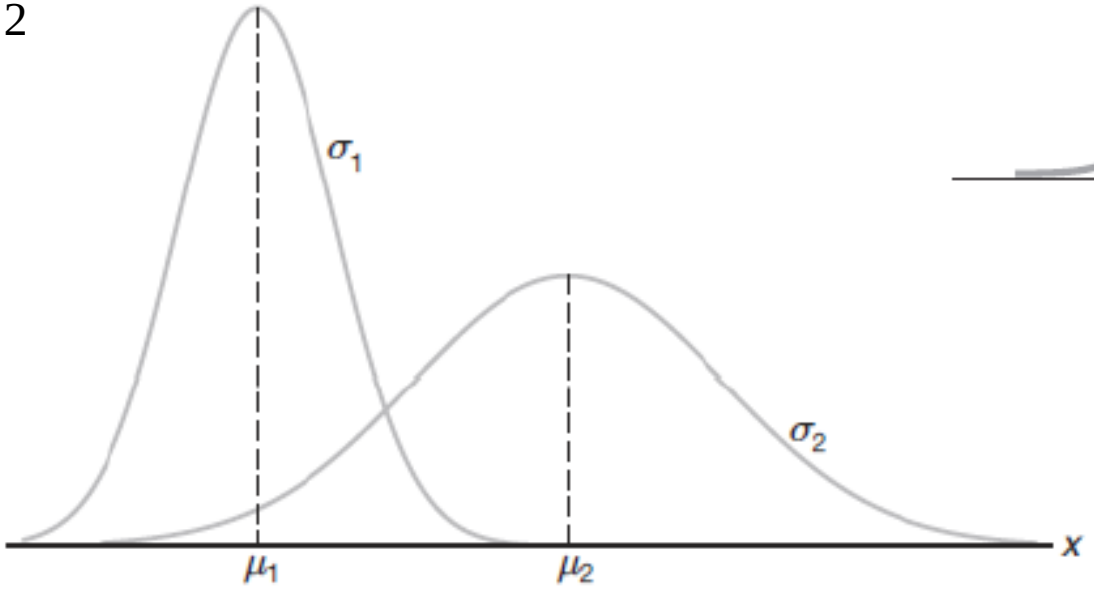
$$\sigma_1 < \sigma_2$$

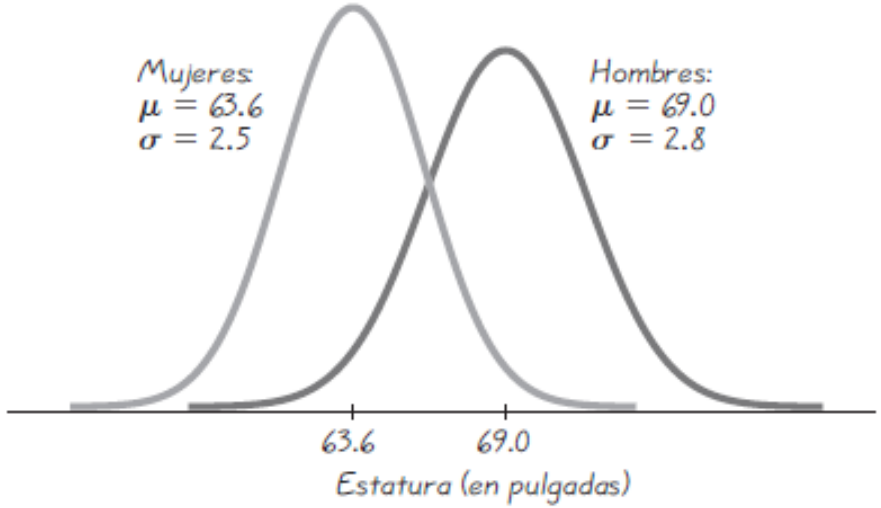
A mayor variabilidad la curva será más plana



$\mu_1 < \mu_2$

$\sigma_1 < \sigma_2$





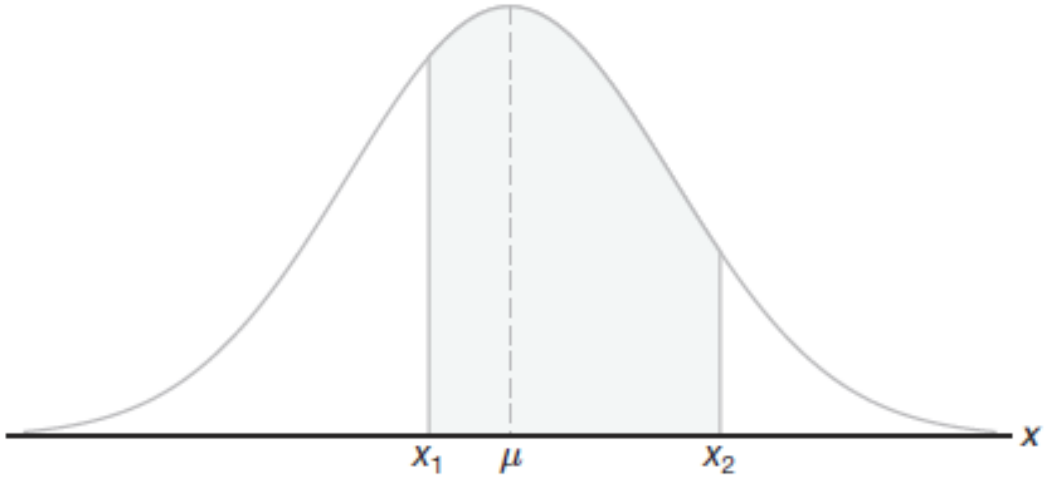
μ_x parámetro de POSICIÓN de la curva normal

σ_x parámetro de FORMA de la curva normal

Por lo tanto, para diferentes valores de la media y desvío estándar se obtiene infinitas curvas normales

CÁLCULO DE PROBABILIDADES CON LA DISTRIBUCIÓN NORMAL

$P(x_1 < x < x_2)$ = Área de la región sombreada



$$P(x_1 < X < x_2) = \int_{x_1}^{x_2} n(x;\mu,\sigma)\,dx = \frac{1}{\sqrt{2\pi\sigma}}\int_{x_1}^{x_2} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}\,dx,$$

Si varían los parámetros μ y σ se obtiene distribuciones normales *diferentes*; por tanto, se tendrá un número infinito de distribuciones, como se muestra en la figura 3.

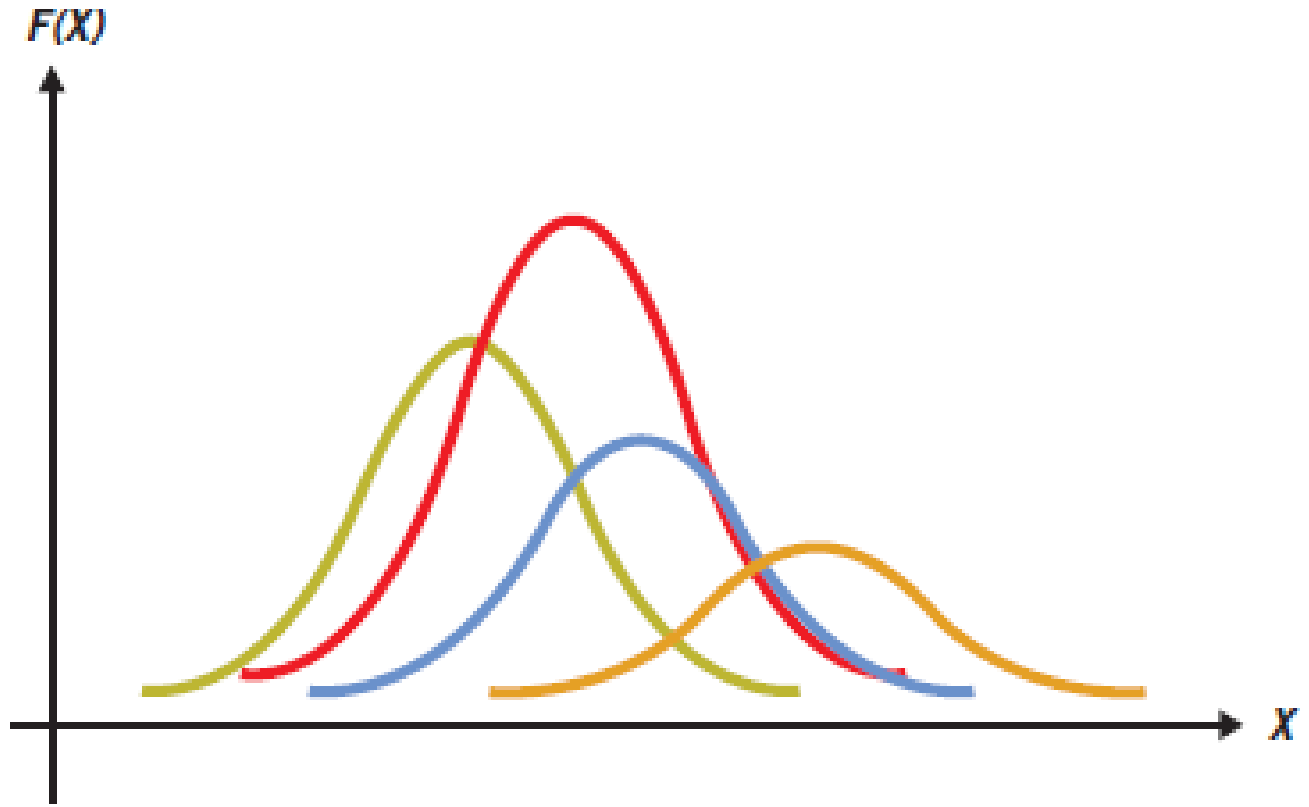
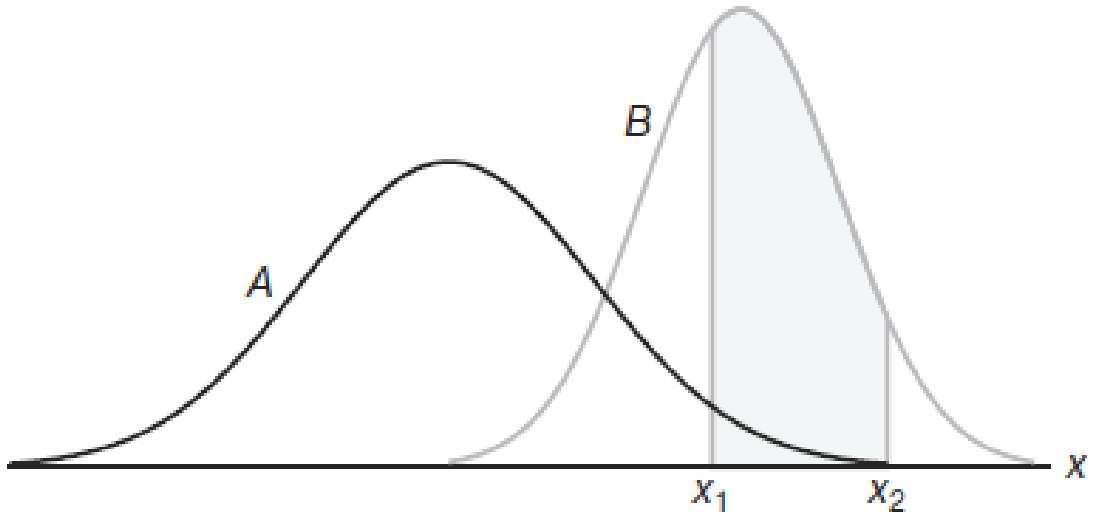


Figura 3 Un número infinito de distribuciones normales debido a la variación de la media y de la desviación estándar poblacionales (μ y σ, respectivamente).



¿Es igual la probabilidad buscada para ambas curvas?

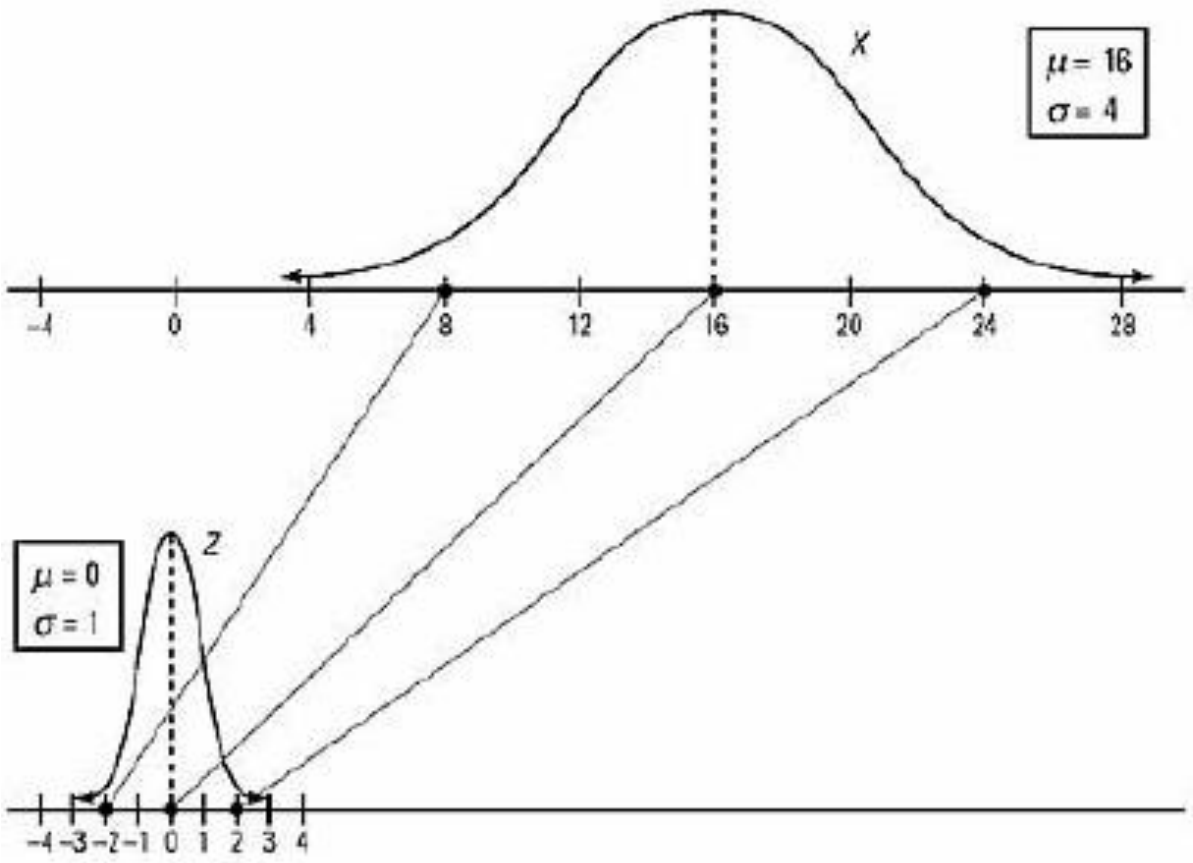
$$P\left(x_1 < x < x_2\right)??$$

DISTRIBUCIÓN NORMAL ESTÁNDAR

$$Z = \frac{X - \mu}{\sigma}.$$

Al hacer la sustitución lograron
obtener una **DISTRIBUCIÓN NORMAL ESTÁNDAR**

$N(0,1)$ LA DISTRIBUCIÓN DE UNA VARIABLE ALEATORIA NORMAL CON MEDIA CERO Y VARIANZA 1 SE LAMA DISTRIBUCIÓN NORMAL ESTÁNDAR



Este proceso de transformar una variable X con distribución normal en una variable Z se llama estandarización

DEMOSTRACIÓN **E(Z)=0**

$$E(Z)=E\left(\frac{X-\mu}{\sigma}\right)=E\left(\frac{X}{\sigma}-\frac{\mu}{\sigma}\right)=E\left(\frac{X}{\sigma}\right)-E\left(\frac{\mu}{\sigma}\right)=\frac{E(X)}{\sigma}-\frac{\mu}{\sigma}=\frac{\mu}{\sigma}-\frac{\mu}{\sigma}=0$$

DEMOSTRACIÓN **VAR(Z)=1**

$$Var(Z)=E(Z)^2-\left[E(Z)\right]^2=E\left(\frac{X-\mu}{\sigma}\right)^2-0^2=E\left(\frac{X^2-2X\mu+\mu^2}{\sigma^2}\right)=$$

$$=E\left(\frac{X^2}{\sigma^2}\right)-2\mu\frac{E(X)}{\sigma^2}+\frac{\mu^2}{\sigma^2}=\frac{E\left(X^2\right)}{\sigma^2}-\frac{2\mu^2}{\sigma^2}+\frac{\mu^2}{\sigma^2}=\frac{E\left(X^2\right)}{\sigma^2}-\frac{\mu^2}{\sigma^2}=$$

$$\frac{E\left(X^2\right)-\mu^2}{\sigma^2}=\frac{\sigma^2}{\sigma^2}=1$$

Propiedades de toda curva normal estándar

1) Es una distribución que caracteriza a las variables aleatorias continuas.
2) La curva normal estándar tienen forma de campana, simétrica con respecto al eje y.
3) Tiene media o esperanza matemática igual a cero y desvío estándar igual a 1.
4) La media, el modo y la mediana son todos coincidentes e iguales a cero.
5) Presenta puntos de inflexión en $Z = \pm 1 = \pm \sigma$
6) Presenta un máximo en $Z = 0$.
7) El área limitada entre la curva normal estándar y el eje z es igual a 1.
8) Es asintótica con respecto al eje z.

RESOLVEMOS EL PROBLEMA INICIAL (PROBLEMA 1)

Datos:

- Media (μ) = 250 ms
- Desvío estándar (σ) = 15 ms
- SLA: [220 ; 280] ms
- Lote: 1000 transacciones

$$P(220 \leq X \leq 280) \approx 95{,}44\%$$

En un lote de 1000 transacciones:

$$1000 \times 0{,}9544 \approx 954 \text{ dentro del SLA}$$

$$1000 - 954 = 46 \text{ fuera del SLA}$$

De cada 1000 transacciones procesadas, **unas 46 no cumplen el SLA**.
☞ Esto muestra por qué la dispersión (σ) es tan importante como la media: ¡aunque el promedio sea justo 250 ms, el sistema no garantiza que todas las transacciones cumplan el SLA!

¿Por qué deberían utilizar distribución normal y no otra?

1) Porque el tiempo de respuesta es una variable continua

El tiempo puede tomar *infinitos valores posibles* (250,3 ms, 250,31 ms, 250,312 ms, etc.), no solo valores enteros. Eso nos orienta a usar **modelos continuos** como la **distribución normal**, y no discretos como binomial o Poisson.

2) Porque el tiempo de respuesta depende de muchas causas pequeñas de variación

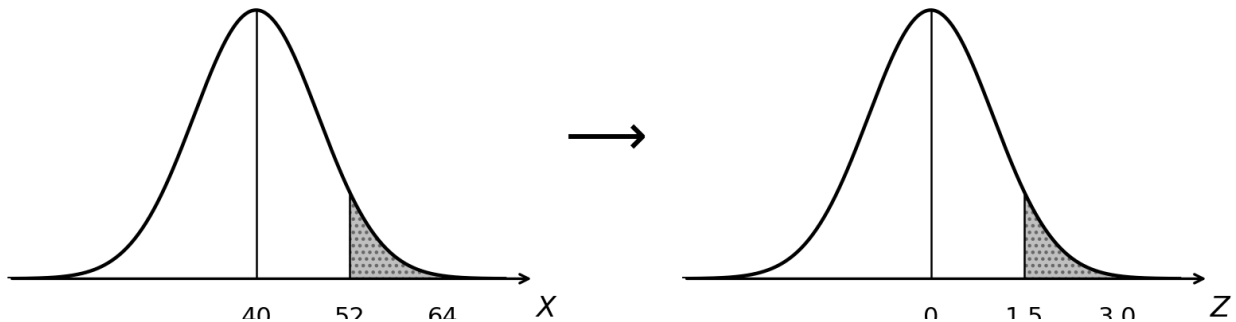
En un sistema informático, el tiempo de respuesta final no depende de una sola cosa, sino de muchas pequeñas variaciones:
mínimas diferencias en la carga del servidor,
latencia de red,
tiempo de acceso a la base de datos,
pausas del recolector de basura (garbage collector),
etc.
Cuando un resultado depende de **muchos factores aleatorios e independientes**, cada uno con un efecto pequeño, se dice que la variable resultante tiende a distribuirse normalmente.

3) Porque la forma del histograma real de los tiempos de respuesta suele ser "en campana"

Si uno mide varios cientos de transacciones y grafica sus tiempos de respuesta, el histograma típico tiene esa forma **simétrica, con la mayoría cerca del promedio**, y pocos valores extremos.
Eso encaja perfecto con la **curva normal**.

EJEMPLO 1

Una empresa de streaming registra que la duración de las sesiones de sus usuarios en la app tiene una media de 40 minutos y desviación estándar de 8 minutos; si se supone que las duraciones se distribuyen normalmente, esto es que las duraciones forman una distribución normal, encuentre el número de sesiones de un total de 10 000 que puede esperarse duren entre 52 y 64 minutos.



Solución: Primero calculamos los puntajes z para $x = 52$ y $x = 64$. El puntaje z para $x = 52$ es

$$\frac{52 - 40}{8} = 1{,}5$$

El puntaje z para $x = 64$ es

$$\frac{64 - 40}{8} = 3{,}0$$

Así,

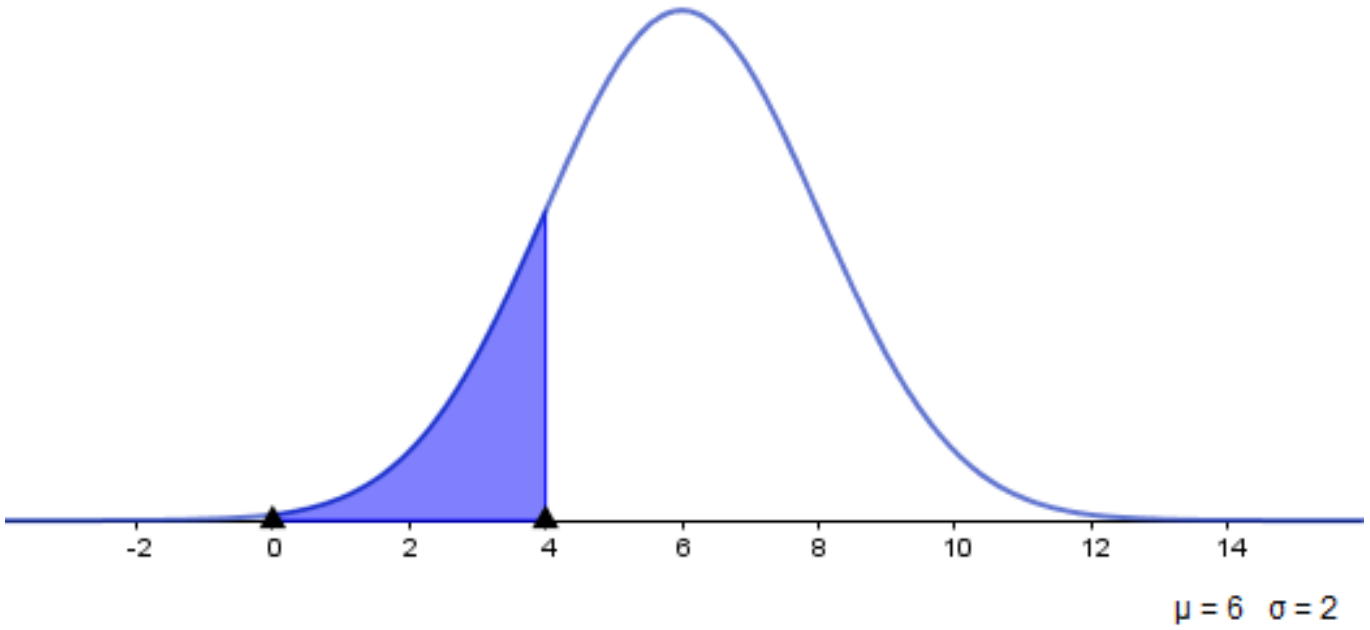
$$P(52 < X < 64) = P(1{,}5 < Z < 3{,}0)$$
$$= 0{,}4987 - 0{,}4332 = 0{,}0655$$

Por tanto, podemos esperar que $(10{,}000)(0{,}0655) = 655$ sesiones duren entre 52 y 64 minutos.

EJEMPLO 2

$\mu = 6 \quad \sigma = 2$

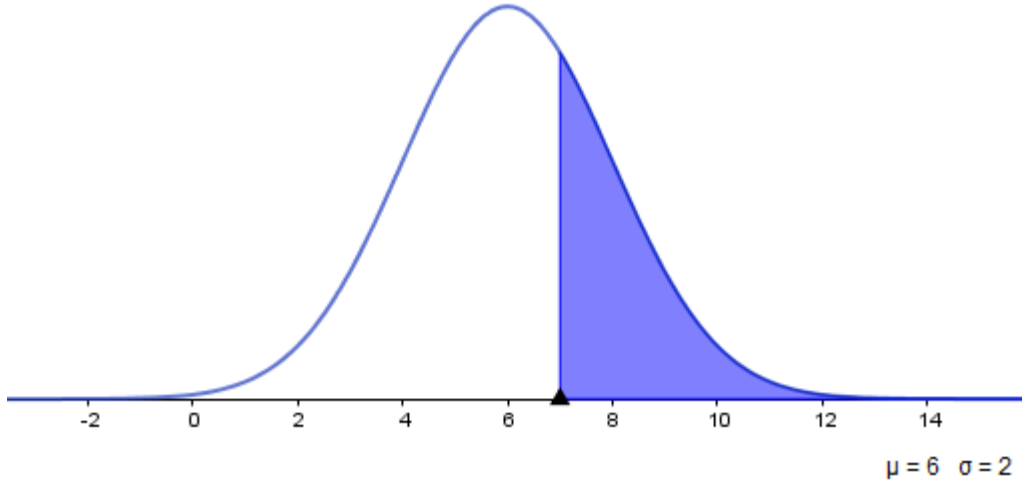
$P(0 < x < 4) = \quad P(-3 < z < -1) = 0{,}1573$



EJEMPLO 3

$\mu = 6 \quad \sigma = 2$

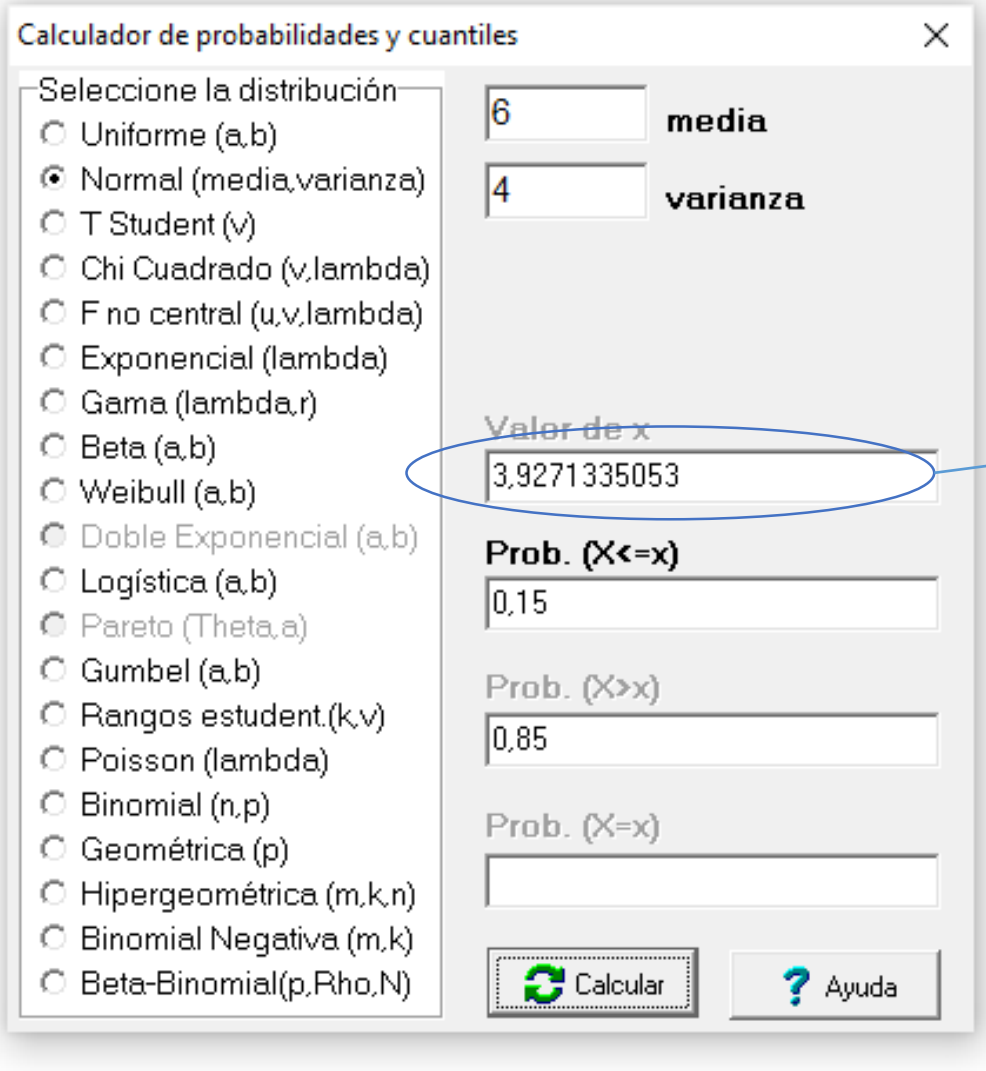
$P(x > 7) =$



EJEMPLO 4

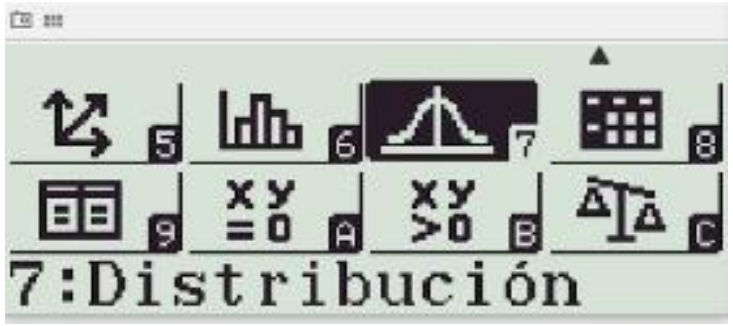
$\mu = 6 \quad \sigma = 2$

$P(x < k) = 0{,}15$



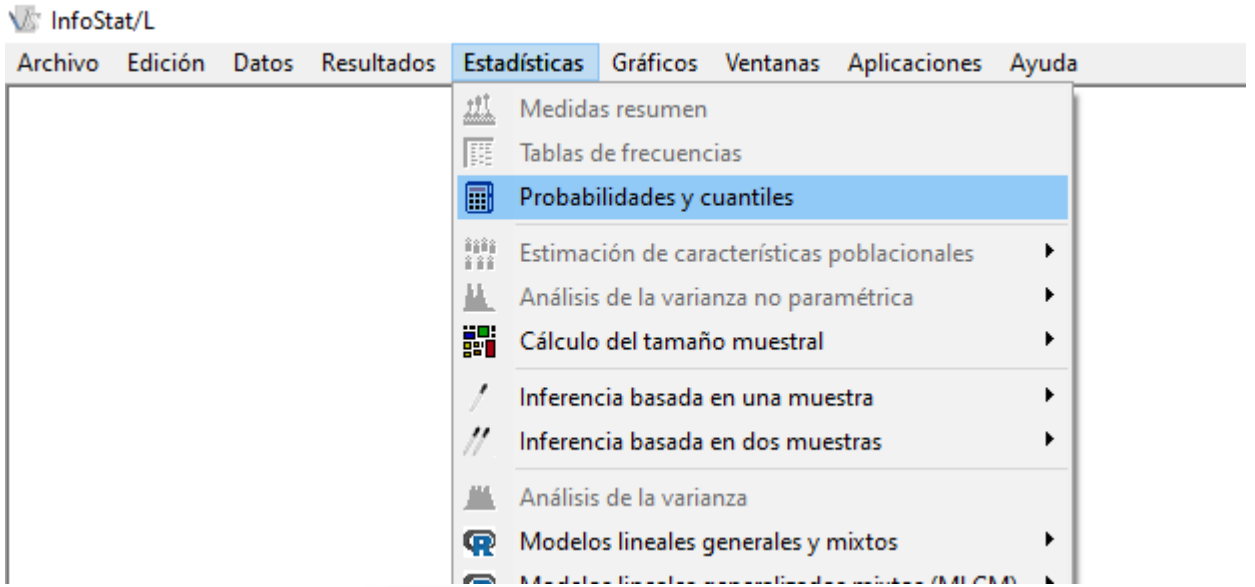
Valor de k buscado

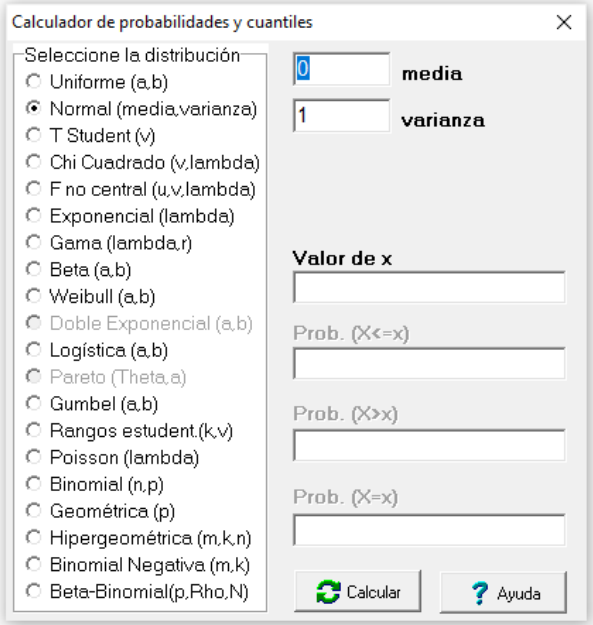
Calculadora





InfoStat





De la guía N°6 . Actividad 1. Ejercicio 9

9) Una encuesta entre los habitantes de cierta ciudad indicó que el ingreso promedio era de $450, con una dispersión de $50. Admitiendo una distribución normal para la variable "ingreso", calcular:

9.1 el porcentaje de habitantes con renta superior a $550.

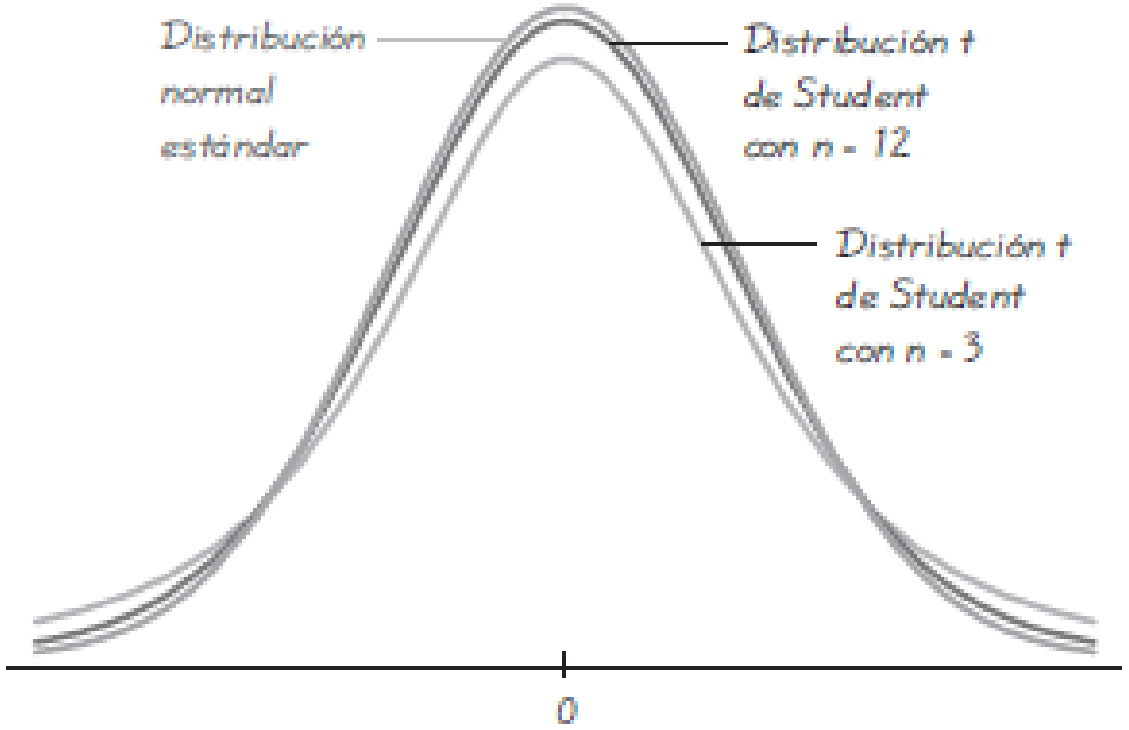
9.2 el porcentaje de habitantes con renta comprendida entre $500 y $525.

9.3 el nivel de renta, a partir del cual encontramos el 10% de mayores ingresos.

DISTRIBUCIÓN T STUDENT ("El detector de muestras pequeñas“)

$$h(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right).\sqrt{\pi.n}}.\left(1+\frac{t^2}{n}\right)^{-\left(\frac{n+1}{2}\right)} \qquad si\ -\infty < t < \infty\ y\ n > 0$$

$$\Gamma(n) = \int_0^{\infty} e^{-x} x^{n-1} dx$$



PROPIEDADES

- Tiene una forma similar a la campana de Gauss, es simétrica respecto del 0, pero presenta colas más gruesas y una parte central más baja.

- Mayor variabilidad cuando se trabaja con muestras pequeñas. A medida que aumentan los grados de libertad (k=n-1), la distribución t se aproxima a la normal estándar.

- A partir de unos 30 grados de libertad, ambas curvas son prácticamente indistinguibles.

- El dominio de la distribución t es el conjunto de los números reales.

- El área total bajo la curva es igual a 1.

- **Se utiliza para estimar parámetros poblacionales (como la media) cuando la varianza poblacional es desconocida y el tamaño muestral es pequeño (n < 30).**

- El parámetro de forma depende del número de grados de libertad (k=n-1).

- Cuanto mayor es k, más se asemeja a la distribución normal.

Grados de libertad: "Es como si tuviéramos cierta libertad para que los datos 'se muevan'. Pero una vez que conocemos la media, todos los valores ya no pueden cambiar libremente: uno de ellos queda determinado. Por eso restamos uno."

•Imagina que la Distribución Normal es la regla estándar cuando conoces a todo el mundo (o tienes datos de miles de personas). Pero, ¿qué pasa cuando solo puedes encuesta a 10 o 15 personas? Ahí entra la t de Student: es una Normal "precavida". Tiene las "colas más anchas" porque asume que, al tener un grupo pequeño, hay mayor margen de error.

• Acepta que con pocos datos hay más incertidumbre. A medida que el grupo de alumnos o datos crece (supera los 30 datos), la curva t se aplasta y se convierte en la Normal de siempre.

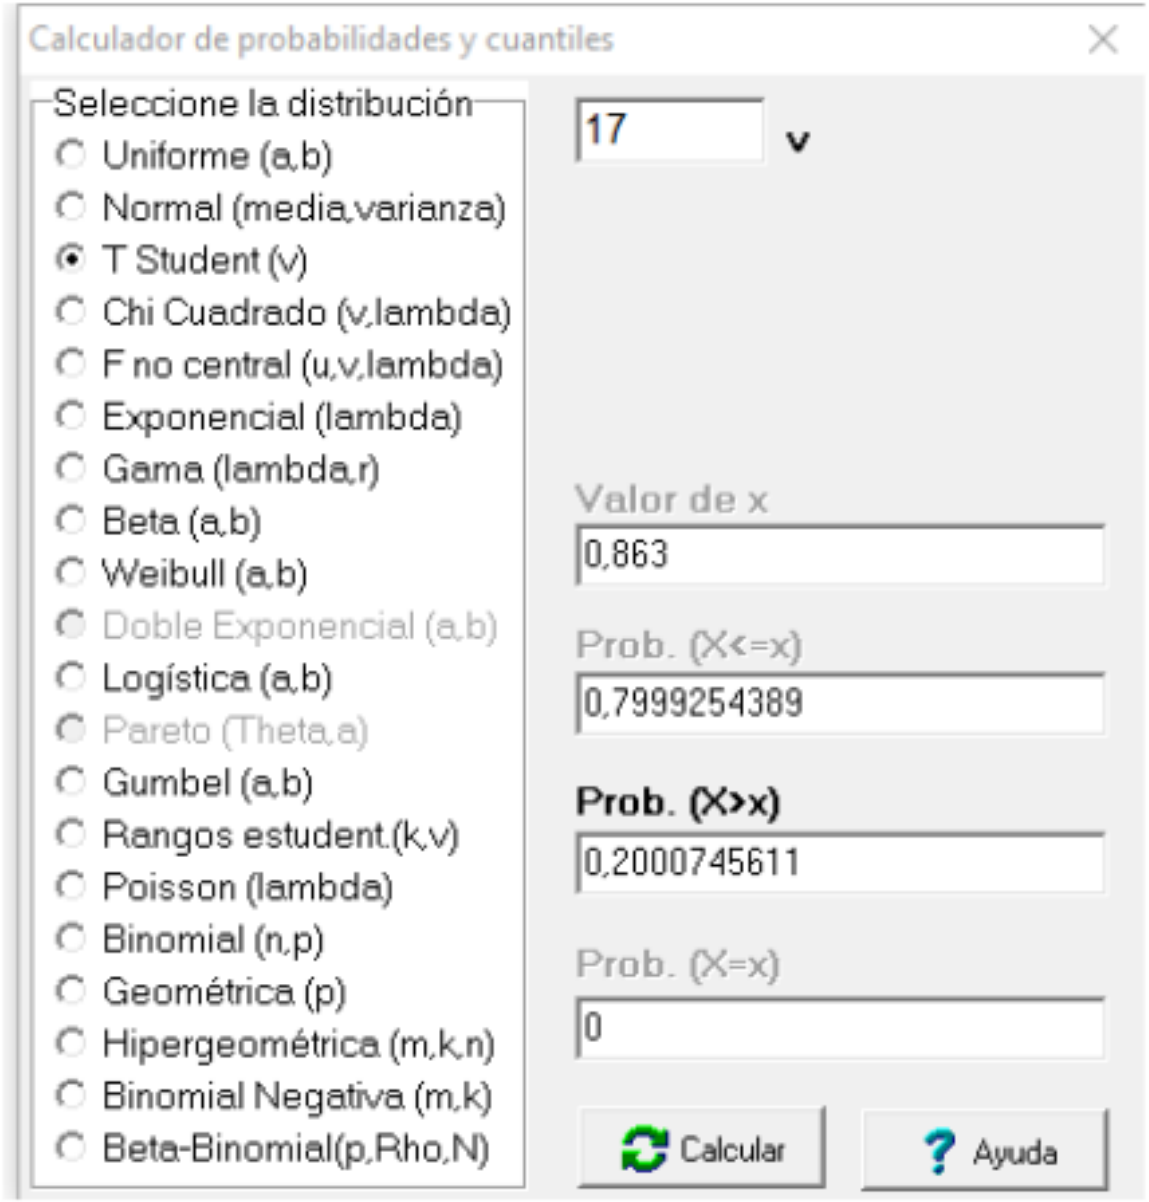
•Hoy la conocemos como una forma geométrica, pero en Inferencia la van a usar para estimar promedios reales (como el sueldo medio o la velocidad media de un sistema) cuando solo tengan una muestra pequeña a mano.

•Usamos la t para muestras chicas, pero con un requisito imprescindible: la variable en la población original tiene que distribuirse como una Normal. Si los datos de origen no son normales, la t pierde precision.

EJEMPLO 1

$$P(t_{17} > 0,863) = 0,20$$

Grados de libertad

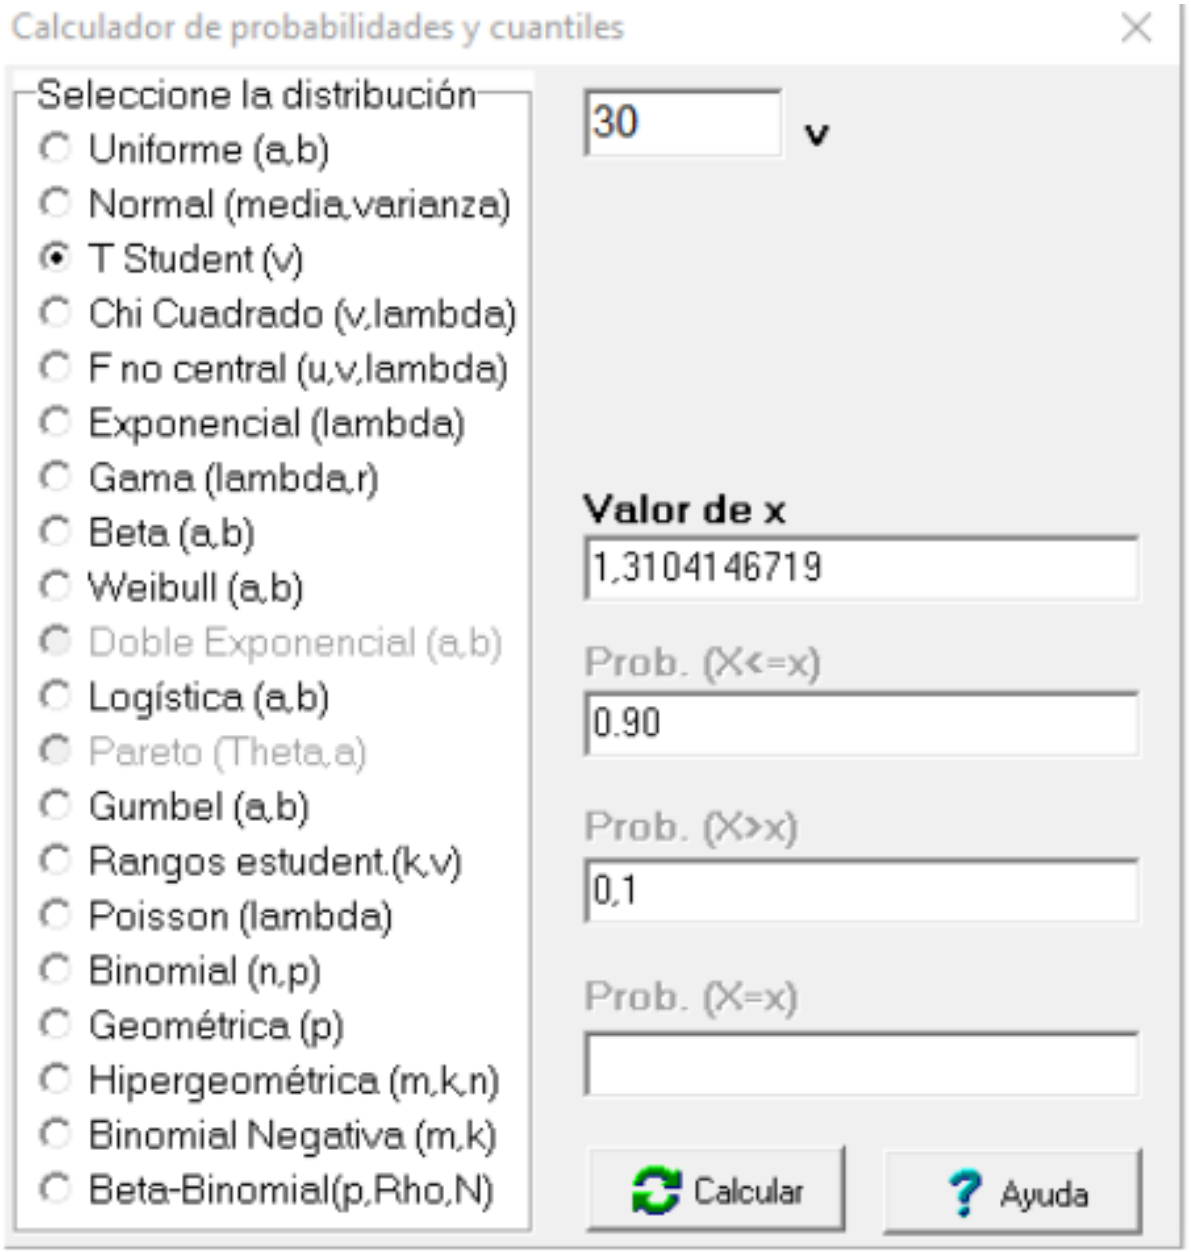


EJEMPLO 2

$$P(t_{30} \leq k) = 0.90$$

Valor de n-1

K=1,31



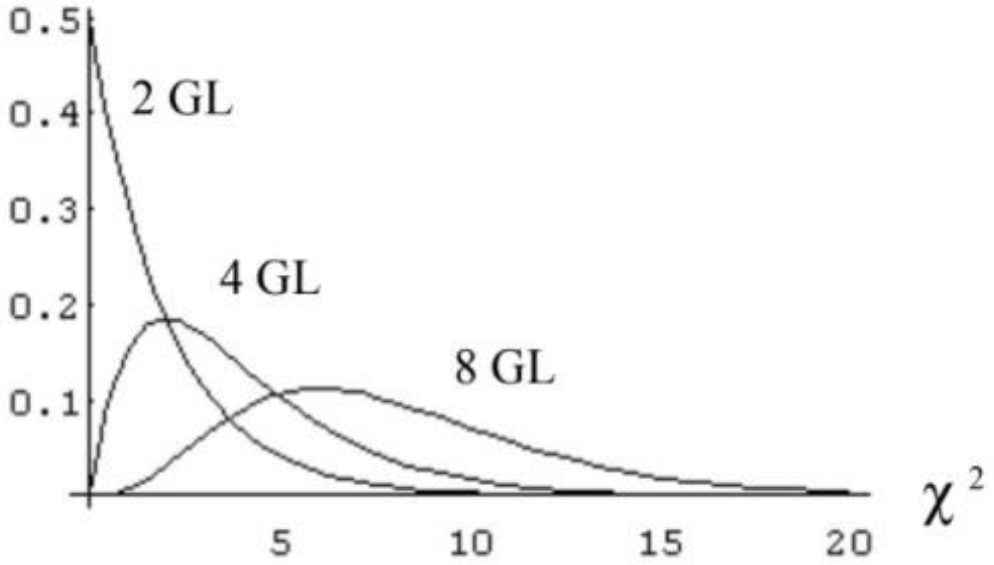
CHI CUADRADO

La distribución chi cuadrado (χ^2) surge al sumar los cuadrados de varias variables normales estándar independientes (N(0,1)).
Su forma depende de una cantidad llamada grados de libertad (gl), que generalmente corresponde al número de variables o de observaciones independientes que se están sumando.

Propiedades de la distribución del estadístico chi cuadrada

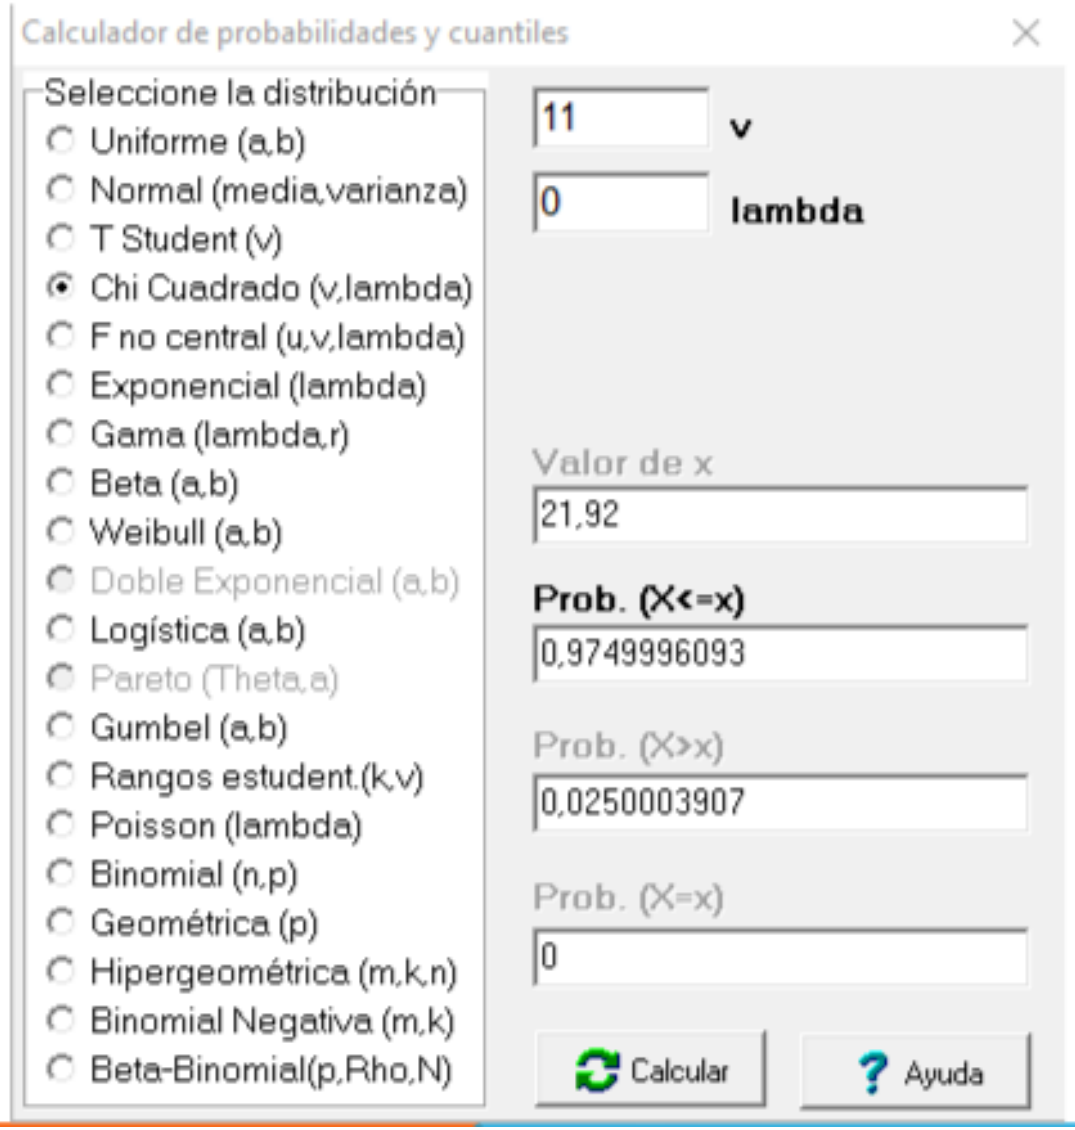
1. La distribución χ^2 no es simétrica, especialmente cuando los grados de libertad son pequeños. A medida que los grados de libertad aumentan, la distribución se vuelve más simétrica y se aproxima a una distribución normal.
2. Los valores posibles de χ^2 son siempre positivos (nunca puede haber valores negativos), porque surgen de sumar cuadrados.
3. La forma de la distribución depende de los grados de libertad (gl):Con pocos gl, la curva es muy asimétrica y concentrada cerca de cero. Con más gl, se desplaza hacia la derecha y se “aplana”.
4. El área bajo la curva es igual a 1, como en toda función de probabilidad continua.
5. Se usa cuando **queremos estimar o contrastar la varianza o desviación estándar poblacional** a partir de una muestra.

$$f(x) = \begin{cases} \dfrac{1}{2^{\frac{n}{2}}\,\Gamma\left(\frac{n}{2}\right)} \cdot x^{\frac{n}{2}-1}\, e^{-\frac{x}{2}} & si\ x > 0 \\ 0 & si\ x \leq 0 \end{cases}$$



EJEMPLOS

$1.1^*\ P(\chi^2_{11} \leq 21{,}92) = 0{,}97$



$1.2^*\ P(\chi^2_{12} \geq k) = 0.10$

K=18,54

